

Residual Reinforcement Learning for Robot Control

标题: Residual Reinforcement Learning for Robot Control

作者: Tobias Johannink*, Shikhar Bahl*, Ashvin Nair*, Jianlan Luo, Avinash Kumar, Matthias Loskyll, Juan Aparicio Ojea, Eugen Solowjow, Sergey Levine (前三位 equal contribution)

机构: Siemens Corporation + UC Berkeley + Hamburg University of Technology

发表: ICRA 2019 (DOI: 10.1109/ICRA.2019.8794127) ; 项目页 <http://residualrl.github.io>

代码: 基于开源 `vitchyr/rlkit` 的 TD3 实现; 本文实验代码无独立公开仓库

一句话总结

把"传统反馈控制器能高效处理的部分"与"RL 学到的残差部分"**相加叠加 (superposition)** , 用 $u = \pi_H(s_m) + \pi_\theta(s_m, s_o)$ 同时获得传统控制的样本效率/稳定性, 和 RL 对接触、摩擦等难建模动态的适应能力。在真实世界 block assembly 任务上, 纯 RL 要从零学控制结构, 而残差 RL 约 **3 小时 (~8k 样本) **就学会对随机朝向块的插入修正。

核心问题

- 传统反馈控制 (PID、计算力矩法) 对路径跟踪高效, 但**接触与摩擦难以用一阶物理模型刻画**——耦合矩阵 $B(s_m, s_o)$ (捕捉接触/摩擦) 通常未知 → 控制器脆、需手工调参、缺乏泛化。
- 纯 RL 能学接触类任务, 但**从零交互学、样本昂贵、初期探索不安全**。
- 本文主张: 多数制造任务"结构可被传统控制部分处理", 把**残差** (接触/物体动力学) 交给 RL。

方法

1. 控制分解 (关键洞察)

奖励可分解为:

$$r_t = f(s_m) + g(s_o)$$

- $f(s_m)$: 机器人状态相关的几何/位置目标 (欧氏距离、期望轨迹) ——**可由传统控制器高效优化**。
- $g(s_o)$: 物体状态相关的通用目标 (如保持块直立) ——**更适合 RL 学细粒度反馈**。

最终控制动作:

$$u = \pi_H(s_m) + \pi_\theta(s_m, s_o)$$

- π_H : 手工设计的反馈控制器 (**固定、不训练**)
- π_θ : RL 学到的残差策略 (参数 θ , 优化任务期望回报)

直觉: 把 π_H 视为"提供指数稳定误差动态的基础层", π_θ 在其上叠加修正。由于 s_m 通过耦合影响 s_o , 需整体优化 (5); 但 π_H 已提供内部结构, 极大简化 $f(s_m)$ 相关优化、缩小 RL 探索空间 (更安全、更省样本)。

2. RL 算法

- 用 **TD3** (twin delayed DDPG, 基于 DDPG 的连续控制 value-based RL) 。

- 选 TD3 原因：稳定、样本高效、少调参；**off-policy**（可在 replay buffer 上离线学，对真实机器人至关重要）。
- 声明方法与**具体 RL 算法无关**，可替换任意 RL。

3. 训练流程（Algorithm 1，真实世界在线）

每个 episode：

1. 采样初始状态 `s_0`
2. 每步 t：
 - 策略动作 $u_t = \pi_\theta(s_t) + N_t$ （ N_t 为探索噪声）
 - **实际执行** $u'_t = u_t + \pi_H(s_t)$ （叠加手工控制器）
 - 存 (s_t, u_t, s_{t+1}) 到 replay buffer R（注意：存的是**残差动作 u_t** ，不含 π_H ）
 - 从 R 采样，用 TD3 优化 θ

要点：训练目标只为残差策略 π_θ ； π_H 始终冻结、仅作推理时叠加。

任务与实验设置

- **任务**：block assembly —— 把一块插入桌上两个站立块之间，**不移动/不推倒它们**（涉及接触、不稳定物体）。Sawyer 7-DoF 臂 + 平行夹爪。
- **仿真**：MuJoCo；**真实**：同构硬件，关节空间柔顺阻抗控制器，相机追踪估计位姿（无真值，仅靠 z 向力）。
- **奖励（仿真）**： $r = -||x_g - x_t||^2 - \lambda(||\theta_l||_1 + ||\theta_r||_1)$ （ x_t 块位置， θ 块倾角）。真实奖励额外加对站立块位姿/朝向的惩罚项。

关键结果

1. **样本效率**：残差 RL 比纯 RL（无 π_H ）学得更快、最终性能更好（仿真+真实）。纯 RL 要从零学位置控制结构，且探索空间更广（硬件上危险）。
2. **环境变化鲁棒性**（块初始朝向随机化）：手工控制器仅 **2/20** 成功，残差 RL **15/20**。学到的"轻微推正"修正行为极难手工指定；真实学习曲线显示 ~8000 样本（约 3 小时）逐渐习得。
3. **控制噪声/偏置恢复**：残差 RL 能补偿有偏/噪声执行器（学更鲁棒解或对抗体偏置），手工控制器随偏置增大性能骤降。
4. **Sim-to-Real**（补充实验）：用仿真训的策略初始化真实世界残差 RL，< **1000 timesteps** 即解决任务——极样本高效。

局限（论文自陈 + 补充）

- π_H 需手工设计且任务相关；若任务结构难用传统控制表达，收益下降（这正是 SPARR 改用"仿真神经网络 base"的动机之一）。
- 残差策略基于**状态/力觉**（非视觉），依赖位姿估计/力传感。
- 真实世界训练仍需真实交互数据（虽少），未做到 SPARR 式"零人工 + 仿真冷启动残差"。
- 仅验证单一 block assembly 任务，规模有限。