

SPARR: sim + real混合框架实现自适应 sim2real



论文: SPARR: Simulation-based Policies with Asymmetric Real-world Residuals for Assembly

作者: Yijie Guo, Iretiayo Akinola, Lars Johannsmeier, Hugo Hadfield, Abhishek Gupta, Yashraj Narang

机构: NVIDIA, University of Washington

核心产物: 一套"仿真训练状态基基础策略 + 真实世界视觉残差策略"的混合框架，让机械臂在零人工干预下把仿真装配策略自适应到真实环境，达成 95–100% 装配成功率。

主要链接: [论文](#)，[代码](#)，[项目主页](#)

一句话总结

SPARR 把"在仿真里用状态信息高效训好的**基础策略**"和"在真实世界里用摄像头学出来的**视觉残差策略**"拼在一起——前者给出靠谱的初始行为和探索方向，后者只负责纠正仿真与现实的偏差，从而**无需任何人类演示/干预**就把两类装配任务的成功率拉到接近满分。


研究问题

机器人精密装配（插孔、对齿、对接）长期难做，因为需要"高精度 + 富接触（contact-rich）"操作。现有两条路线各有硬伤：

1. **纯仿真 / sim-to-real（如 AutoMate）**：在仿真里训得很好（成功率常 >99%），但一上真实机器人就被 **sim-to-real gap** 拖垮——质量/摩擦等物理参数不匹配、相机标定误差、位姿估计噪声、视觉域偏移（光照/外观/背景），真实成功率掉到中等（最高约 80%），达不到工业部署要求的 95%+。
2. **纯真实世界 RL（如 SERL / HIL-SERL）**：绕开了 sim-to-real gap，但严重依赖人类专家演示 + 训练中的频繁干预/监督，难以规模化。HIL-SERL 虽然能做到亚毫米精度，但那是有人力兜底的上界。

核心问题: 能不能兼得两边的便宜——用仿真的高效与结构化先验，又靠真实世界数据做自适应，还完全不靠人？

核心方法



1. 问题形式化 (MDP)

任务建模为标准马尔可夫决策过程 $M = \{S, A, \rho, P, r, \gamma\}$ 。每步：状态 $s_t \in S$ （机器人本体信号 + 零件位姿或视觉观测），动作 $a_t \in A$ （末端执行器增量位姿目标），奖励 r_t ，折扣 γ 。策略 $\pi(a_t|s_t)$ 最大化累积折扣回报。

公式直觉解读：就是强化学习的"标配剧本"——把装配看成一个序贯决策问题，智能体每步选一个微小动作，目标是让长期回报最大。这里真正的看点不在 MDP 本身，而在下面如何"asymmetric (非对称)"地训练两个策略。

2. 仿真预训练：状态基基础策略 π_b (Sec. III-B)

- **观测 s_t^b ：** 机器人关节角、当前末端位姿、目标末端位姿、以及它们的差值（沿用 AutoMate 设定）。**不含图像。**
- **动作 a_t ：** 增量位姿目标，由一个 Cartesian 阻抗控制器跟踪执行。
- **训练：** 用 **PPO**，奖励来自**拆解轨迹 (disassembly) 的模仿奖励**（即让策略学会"反着拆"的逆过程）。
- **输出：** 高斯动作 $a_t \sim \mathcal{N}(\mu_t, \sigma_t)$ 。
- **技巧：** 每局随机化关节构型、插座位姿、插头位姿 (domain randomization)；配合并行仿真 (128 环境)、稠密奖励，一天训完 2500 万步，仿真成功率 >99%。

公式直觉解读：为什么用"状态"而不是"图像"在仿真里训？因为**状态信息干净、稠密奖励好给、并行快**；**图像策略要搞大规模域随机化 + 高保真渲染才抗域偏移，贵且慢**。基础策略相当于一个"在理想物理里练熟了动作套路"的老师傅，但它对真实世界的脏数据没有抵抗力。

3. 真实世界部署基础策略 π_b (Sec. III-C)

和仿真预训练属同策略只是 s_t^b 里的目标位姿改成由 Grounding DINO + SAM2 + FoundationPose 估计的插座位姿，并人为加 $\pm 1\text{mm}$ 均匀噪声来模拟估计误差。

- 真实世界里用 **Grounding DINO + SAM2 + FoundationPose** pipeline 估计插座位姿，目标位姿 = 估计插座位姿 + z 方向偏移（假设插头已被稳定夹住）。
- 实测估计位姿与真值差距在 x、y 轴 $\pm 1\text{mm}$ 内。于是论文在每局开始时，对真值目标位姿**人为叠加 $\pm 1\text{mm}$ 均匀噪声**，来建模位姿估计误差；且**刻意不直接把估计位姿喂给策略**，避免过拟合到特定估计器的误差分布。
- 每局初始化：夹着插头的末端停在"带噪声目标位姿"上方 2cm 处。
- 结果：因动力学不匹配 + 状态输入不准， π_b 真实零样本成功率只有中等。

公式直觉解读：这一步其实是在"主动造假噪声"做压力测试——**既然真实位姿估不准，就干脆在训练/评测里把目标位姿扰上 1mm，看策略抗不抗造**。而且不把估计值直接当输入，是防止策略"记住"某个估计器的独特偏差，换个别的感知前端就垮。

4. 残差策略 π_r (Sec. III-E) —— SPARR 的灵魂

- **输入 s_t^r ：**低维本体状态（末端位姿、线/角速度、力/力矩）+ **两路腕部 RGB 图像**。**刻意不含任何物体位姿**，因此对位姿估计误差天然免疫。视觉还能提供 CAD 模型里没有的信息：不对称外形、纹理、制造公差/缺陷、细粒度接触特征（比如 USB 插座的单向插入约束，位姿估计器给不出，但图像能看出）。
- **输出：**残差动作 a_t^r （增量位姿目标），**叠加**到基础动作 a_t^b 上。
- **条件输入：**残差策略同时以 (s_t^r, a_t^b) 为条件——基础动作给残差提供了"当前在做什么、该往哪补"的上下文。
- **算法：**采用 **RLPD**（sample-efficient 离线+在线 RL），每次更新**从演示缓冲 $\mathcal{B}_{demo}$ 和在线 RL 缓冲 $\mathcal{B}_{RL}$ 各抽 50% 样本**。
 - $\mathcal{B}_{demo}$ 用 Sec. III-D 收集的离线成功轨迹初始化；
 - 训练中，把"比已有演示中位耗时更快就成功"的高质量轨迹持续补进 $\mathcal{B}_{demo}$ ，让策略利用训练中发现的好经验、**压缩周期时间（cycle time）**。
- **奖励（稀疏）：**

$$r_t = \begin{cases} 1 & \|\text{pos}_t - \text{pos}^*\| \leq 3\text{mm} \text{ 且 } \angle(\text{rot}_t, \text{rot}^*) \leq 5^\circ \\ 0 & \text{否则} \end{cases}$$

公式直觉解读（稀疏奖励为何合理）： 富接触插入时，"离目标还有多远"是个**会骗人**的信号——插头可能被插座壁挡住，直线距离近但根本插不进去。所以论文只在"真正坐进去了"（位姿误差 $< 3\text{mm} / 5^\circ$ ）才给 1 分，其余全 0。这逼策略去学"怎么绕过几何障碍完成插入"，而不是去最小化一个误导性的距离。

公式直觉解读（50/50 缓冲采样）： 演示缓冲 = 安全、成功的"标准答案"先验；在线 RL 缓冲 = 真实世界里探索出的修正经验。各抽一半，等于让策略"既别忘了怎么成功，又能继续摸索更好的修正"，避免纯离线（不会进步）或纯在线稀疏奖励（探索崩盘，见 SERL 失败）。

5. 演示收集的技巧：用零均值残差"伪装"成基础策略（Sec. III-D，很妙）

真实世界里没有残差的 ground-truth 标签。论文的做法：

- 基础策略输出高斯分布 $a_t^b \sim \mathcal{N}(\mu_t, \sigma_t)$ ，取均值作确定性基础动作 $a_t^b = \mu_t$ 。
- 残差伪标签从 $a_t^r \sim \mathcal{N}(0, \sigma_t)$ 采样（和基础的方差相同、零均值）。
- 组合动作定义为 $a_t = a_t^b + a_t^r$ 。

公式直觉解读（关键洞见）： 因为 a_t^r 是零均值、方差还是 σ_t ，把它加到常数 μ_t 上，组合动作的分布恰好等于 $\mathcal{N}(\mu_t, \sigma_t)$ ——**和基础策略自己的输出分布一模一样**。这意味着：真实世界里的这趟 rollout，"看上去"完全就是基础策略在自然环境里正常探索；但我们同时把 (s_t^r, a_t^r, r_t) 三元组记录下来。于是不花一个**人力演示**，就白嫖到教残差策略"该补多少修正"的监督信号。零样本部署注入这种残差后，筛出成功的轨迹当演示缓冲。

6. 部署时的组合（Fig. 3）

执行动作 $a_t = a_t^b + a_t^r$ ，两者都 clamp 到 $[-1, 1]$ （增量目标位姿范围）。基础策略负责"大方向"，残差策略负责"临门一脚的微修正"。

主要结果

A. 真实世界自适应（10 个 AutoMate 任务，Fig. 4）



- 固定训练预算 **0.5 小时/任务**，动作 15 Hz，20 局评测（带噪声目标位姿）。
- **SPARR 成功率 95–100%**；相比 SOTA 零样本 sim-to-real（AutoMate）：**成功率相对 +38.4%、周期时间 -29.7%**（10 任务平均）。
- **SERL**（无人工演示的真实世界 RL）表现差——稀疏奖励下硬探索，20 演示 + 0.5h 根本学不出正样本。
- SPARR 达到与 **HIL-SERL（人类近优演示 + 持续干预）** 相当的成功率，**全程零人工监督/干预**。
- 周期时间仍略高于 HIL-SERL：因 sim-to-real 方法用了动作平滑 + PLA1 积分器拖慢执行，且人类演示本身更快。

B. 对状态噪声的鲁棒性（Fig. 5）

- 把插座物理位移 2cm + 每局叠加 1mm 位姿噪声。
- 对比"状态基残差"变体：状态基残差对估计误差和分布外插座位置敏感、性能掉得狠。
- **图像基残差（SPARR）** 平均比基础策略 **+38.6%**，比状态基残差 **+20.8%**；只有在极端位姿偏移（导致基础动作分布外）时才略降。

C. 泛化到未见过任务（NIST 板，Fig. 6/7）

- 从 AutoMate 里挑"尺寸/行为最像"的基础策略迁移到未见过的 NIST 任务：
 - 4mm 圆销 ← AutoMate 01041（最小插头 6mm）；

- 12mm 方销 ← AutoMate 00731 (10mm 圆销) ；
- 小齿轮 ← AutoMate 00768 (盖帽到圆柱) 。
- 圆销 80% (反光白板上的小孔极难被视觉检测，残差主要靠本体状态补救) ；方销 100% (残差学会了补 $\pm 3^\circ$ 偏航对齐) ；齿轮 100% (间隙仅 0.005–0.014mm，残差同时修正角度与用力) 。
- **NIST 任务整体：成功率相对 +74.5%、周期时间 -36.5%**

D. 消融实验 (Table I / II)

- **演示缓冲在线更新** (Table I, 任务 01041/01036) : 不更新 → SPARR(ours) 成功率 0.8→1.0 / 0.8→1.0, 周期时间也进一步下降 (如 01041: 10.76→6.81s)。说明把"更快成功的轨迹"回灌演示缓冲确实压缩了周期。
- **残差是否以基础动作为条件** (Table II, 任务 00015/00768) : 去掉基础动作输入，成功率与周期时间都劣于 SPARR(ours) (00015: 0.75→1.0; 00768: 0.65→0.95, 周期 10.19→6.11s)。印证"基础动作当上下文"的设计必要。

创新点

1. **非对称残差框架 (Asymmetric Residual)** : 基础策略在仿真用**状态+稠密奖励**训 (高效、结构化先验、安全探索) ；残差策略在真实用**视觉+稀疏奖励**训 (补动力学/传感器/视觉偏差)。两边各取所长。
2. **零人工监督达成近满分** : 相对 HIL-SERL (靠人) 不落下风，但**完全不要人类演示或干预**，可规模化。
3. **残差演示的"白嫖"技巧** (Sec. III-D) : 注入零均值、同方差残差，使组合动作分布与基础策略一致，从而**无成本采集** (s^r, a^r, r) **监督对**——这是整个方法能在真实世界冷启动的关键。
4. **视觉残差对位姿噪声免疫** : 输入刻意不含物体位姿，靠图像扛住 $\pm 1\text{mm}$ 估计误差和 2cm 插座位移。
5. **RLPD + 演示缓冲在线更新** : 50/50 采样抗稀疏奖励，快轨迹回灌进一步压周期时间。

局限性 (作者自述)

1. 假定插头已被刚性预抓取在夹爪里，不涉及"抓取→插入"全链路，对抓取扰动不鲁棒。
2. 依赖基础策略有"尚可"的零样本迁移：若基础策略**真实成功率近 0**，残差 alone 救不回来。
3. 要求部署时有**自动化的奖励/成功检测** (靠位姿判定成功，需真值或可靠估计) 。
4. 周期时间仍略高于有人力兜底的方法 (PLAI 平滑 + 演示质量限制) 。
5. 目前只验证了**小零件插入式装配** (平均插头直径 $< 1\text{cm}$)，未覆盖更复杂多步装配。